

Завдання 1

Кувавiна Софiя

Знайти набiр даних, описати данi, що мiстяться по стовбцях випадку прямокутних даних. Надати метаданi для цього датасету та додати до завдання. Все викладати у гугл клас до цього завдання.

Бажано, щоб датасет мiстив не менше 5000 записiв.

```
import pandas as pd
import numpy as np
from scipy import stats
import matplotlib.pyplot as plt
import seaborn as sns
df = pd.read_csv("anime.csv")
print("Розмiр:", df.shape)
df.head()
```

Розмiр: (12294, 7)

	anime_id	name	genre	type	episodes	rating	members
0	32281	Kimi no Na wa.	Drama, Romance, School, Supernatural	Movie	1	9.37	200630
1	5114	Fullmetal Alchemist: Brotherhood	Action, Adventure, Drama, Fantasy, Magic, Mili...	TV	64	9.26	793665
2	28977	Gintama°	Action, Comedy, Historical, Parody, Samurai, S...	TV	51	9.25	114262
3	9253	Steins;Gate	Sci-Fi, Thriller	TV	24	9.17	673572
4	9969	Gintama'	Action, Comedy, Historical, Parody, Samurai, S...	TV	51	9.16	151266

```
df.info()
print("\n[46] числових стовпцiв:")
print(df.describe())
print("\n[46] кiлькiсть пропущених значень:")
print(df.isnull().sum())
```

[46]

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 12294 entries, 0 to 12293
Data columns (total 7 columns):
#   Column      Non-Null Count  Dtype
---  -
0   anime_id    12294 non-null  int64
1   name        12294 non-null  object
2   genre       12232 non-null  object
3   type        12269 non-null  object
4   episodes    12294 non-null  object
5   rating      12064 non-null  float64
6   members     12294 non-null  int64
dtypes: float64(1), int64(2), object(4)
memory usage: 672.5+ KB
```

Опис числових стовпцiв:

	anime_id	rating	members
count	12294.000000	12064.000000	1.229400e+04
mean	14058.221653	6.473902	1.807134e+04
std	11455.294701	1.026746	5.482068e+04
min	1.000000	1.670000	5.000000e+00
25%	3484.250000	5.880000	2.250000e+02
50%	10260.500000	6.570000	1.550000e+03
75%	24794.500000	7.180000	9.437000e+03
max	34527.000000	10.000000	1.013917e+06

```
...
episodes    0
rating      230
```

-Очистити датасет від викидів, рядків, що не містять значень.

```
df_clean = df.copy()
df_clean = df_clean.dropna(subset=["rating"])
df_clean = df_clean[df_clean["rating"] > 0]
df_clean["episodes"] = pd.to_numeric(df_clean["episodes"], errors="coerce")
df_clean = df_clean.dropna(subset=["episodes"])
Q1 = df_clean["rating"].quantile(0.25)
Q3 = df_clean["rating"].quantile(0.75)
IQR = Q3 - Q1
lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR
df_clean = df_clean[(df_clean["rating"] >= lower_bound) & (df_clean["rating"] <= upper_bound)]
df_clean.to_csv("anime_clean.csv", index=False)
print("Очищено")
removed_percent = (1 - len(df_clean) / len(df)) * 100
print(f"Видалено {removed_percent:.2f}% рядків як викиди")
print("Було рядків до:", len(df))
print("Залишилось рядків після:", len(df_clean))
print("Видалено:", len(df) - len(df_clean))
```

Очищено

Видалено 5.24% рядків як викиди

Було рядків до: 12294

Залишилось рядків після: 11650

Видалено: 644

Також вказала тут відсоток викидів та до/після

-Порахувати середнє, усічене середнє, медіану, дисперсію, стандартне відхилення, середнє відхилення, абсолютно медіане відхилення.


```
score = df_clean["rating"]
mean = score.mean()
trimmed_mean = stats.trim_mean(score, 0.05)
median = score.median()
variance = score.var()
std_dev = score.std()
mean_abs_deviation = np.mean(np.abs(score - mean))
median_abs_deviation = stats.median_abs_deviation(score)

stats_data = {
    "mean": mean,
    "trimmed_mean": trimmed_mean,
    "median": median,
    "variance": variance,
    "std_dev": std_dev,
    "mean_abs_deviation": mean_abs_deviation,
    "MAD": median_abs_deviation
}

pd.DataFrame([stats_data]).to_csv("anime_stats.csv", index=False)
pd.DataFrame([stats_data])
```

	mean	trimmed_mean	median	variance	std_dev	mean_abs_deviation	MAD
0	6.532633	6.549783	6.59	0.887727	0.942193	0.751086	0.63

-Нормалізувати дані мін. мах та середня нормалізація.



-Намалювати 3 графіки.

