

Завдання 2

Кувавiна Софiя

Завдання:

Зробити кластерний аналіз свого датасету.

Метод к-середніх:

-Надати оптимальну кількість кластерів(Наприклад,метод ліктя. Якщо інший то напишіть який саме використовували. Намалювати графік, який відображає оптимальність кластерів);

-Надати таблицю з цетрами кластерів та кількістю елементів;

-Намалювати кластери різними кольорами на одній сітці та їх центри.

Також вкажуйте, яку метрику ви використовували для визначення радіусу кластера(евклідову, манхетенську тощо).

Ієрархічний метод:

- Намалювати дендограму;

- Визначити оптимальну кількість кластерів: якщо з візуалізації, по поясніть, чому саме така кількість кластерів;

- Надати таблицю з кількістю елементів по кластерам;

Порівняти кількість та збалансованість кластерів в цих двох кластерних аналізів.

Оформити в бажано одним файлом.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import silhouette_score
from scipy.cluster.hierarchy import linkage, dendrogram, fcluster
from sklearn.decomposition import PCA
import os

data_path = r"S:\навчання\мтад\anime.csv"
save_path = r"S:\навчання\мтад\lab2"
os.makedirs(save_path, exist_ok=True)
data = pd.read_csv(data_path)
data_num = data.select_dtypes(include=[np.number]).dropna()

scaler = StandardScaler()
X = scaler.fit_transform(data_num)
# тут шукаю оптимальне k за допомогою методу ліктя !!!
inertias = []
silhouettes = []

for k in range(2, 11):
    kmeans = KMeans(n_clusters=k, random_state=0, n_init=10)
    kmeans.fit(X)
```

```

inertias.append(kmeans.inertia_)
labels = kmeans.labels_
silhouettes.append(silhouette_score(X, labels))

plt.plot(range(2, 11), inertias, marker='o')
plt.title("Метод ліктя")
plt.xlabel("Кількість кластерів (k)")
plt.ylabel("Inertia")
plt.grid()
plt.savefig(save_path + "\\elbow.png")
plt.close()

plt.plot(range(2, 11), silhouettes, marker='o')
plt.title("Silhouette метод")
plt.xlabel("Кількість кластерів (k)")
plt.ylabel("Silhouette Score")
plt.grid()
plt.savefig(save_path + "\\silhouette.png")
plt.close()

best_k = np.argmax(silhouettes) + 2
print("Оптимальне k =", best_k)

# використовується евклідова відстань
kmeans = KMeans(n_clusters=best_k, random_state=0, n_init=10)
labels_k = kmeans.fit_predict(X)

centers = scaler.inverse_transform(kmeans.cluster_centers_)
centers_df = pd.DataFrame(centers, columns=data_num.columns)
centers_df.to_csv(save_path + "\\kmeans_centers.csv", index=False)

counts_k = pd.Series(labels_k).value_counts().sort_index()
counts_k.to_csv(save_path + "\\kmeans_counts.csv")

pca = PCA(n_components=2)
X2 = pca.fit_transform(X)
centers2 = pca.transform(kmeans.cluster_centers_)

plt.figure()
for i in range(best_k):
    plt.scatter(X2[labels_k == i, 0], X2[labels_k == i, 1], label=f"Кластер {i}")
plt.scatter(centers2[:, 0], centers2[:, 1], c="red", marker="X", s=200, label="Центри")
plt.legend()
plt.title("KMeans кластери (PCA)")
plt.savefig(save_path + "\\kmeans_clusters.png")
plt.close()
link = linkage(X, method='ward')
plt.figure(figsize=(10, 5))
dendrogram(link)
plt.title("Ієрархічна дендрограма")
plt.savefig(save_path + "\\dendrogram.png")

```

```
plt.close()


labels_h = fcluster(link, best_k, criterion='maxclust') - 1
counts_h = pd.Series(labels_h).value_counts().sort_index()
counts_h.to_csv(save_path + "\\hier_counts.csv")

data_out = data_num.copy()
data_out["kmeans"] = labels_k
data_out["hier"] = labels_h
data_out.to_csv(save_path + "\\clusters_with_labels.csv", index=False)
```


Вивід

```
PS D:\Sofiya\vscode> python script.py
Оптимальне k = 3
```


Графік методу ліктя:



Графік коефіцієнта силуету:



Візуалізація кластерів методом K-Means:



Таблиця з координатами центрів кластерів:

	A	B	C
1	anime_id	rating	members
2	26592.32997	5.915484981	5471.039211
3	6104.612483	6.722585734	12574.3192
4	11765.18886	7.980799031	254232.9031

Таблиця з кількістю елементів у кожному кластері (метод KMeans):

	A	B
1		count
2	0	4362
3	1	7289
4	2	413

Таблиця з кількістю елементів у кожному кластері, отриманих ієрархічним методом:

	A	B
1		count
2	0	4787
3	1	375
4	2	6902

Основний фінальний файл:

anime_id	rating	members	kmeans	hier
32281	9.37	200630	2	1
5114	9.26	793665	2	1
28977	9.25	114262	2	0
9253	9.17	673572	2	1
9969	9.16	151266	2	1
32935	9.15	93351	0	0
11061	9.13	425855	2	1
820	9.11	80679	1	2
15335	9.1	72534	1	0
15417	9.11	81109	1	0
4181	9.06	456749	2	1
28851	9.05	102733	2	0
918	9.04	336376	2	1
2904	8.98	572888	2	1
28891	8.93	179342	2	1
199	8.93	466254	2	1
23273	8.92	416397	2	1