

## Завдання 4

### Кувавiна Софiя

Прокласифікувати методом К найближчих суддів:

- поділити вибірку на тестову та початкову;
- розрахувати скільки потрібно обрати найближчих записів, щоб точність була не нижче 85%;
- порахувати точність для тестової вибірки;
- зробити крос валідацію на 3 блоках;
- зробити висновки.

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split, cross_val_score
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score

data = pd.read_csv(r"S:\навчання\мтад\lab2\clusters_with_labels.csv")

top2 = data['kmeans'].value_counts().index[:2]
data2 = data[data['kmeans'].isin(top2)]

X = data2.select_dtypes(include=[np.number]).drop(columns=['kmeans', 'hier'],
errors='ignore')
y = data2['kmeans']
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=0, stratify=y)

scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

best_k = 0
best_cv_mean = 0
best_test_acc = 0

for k in range(1, 30):
    knn = KNeighborsClassifier(n_neighbors=k)
    cv_scores = cross_val_score(knn, X_train, y_train, cv=3)
    cv_mean = cv_scores.mean()

    knn.fit(X_train, y_train)
    test_acc = accuracy_score(y_test, knn.predict(X_test))

    if test_acc >= 0.85 and cv_mean > best_cv_mean:
        best_k = k
        best_cv_mean = cv_mean
        best_test_acc = test_acc
```

```

print(f"Обране k = {best_k}")
print(f"Точність на тестовій вибірці: {best_test_acc*100:.2f}%")
print(f"Середня точність крос-валідації: {best_cv_mean*100:.2f}%")

if best_test_acc >= 0.85:
    print("Висновок: модель досягла потрібної точності ≥85%")
else:
    print("Висновок: модель не досягла 85%, але обране k дає найкращу стабільну точність")

```

- Поділ даних на навчальну та тестову вибірки

Дані діляться у співвідношенні **80% навчальних / 20% тестових**

Використовуємо stratify=y, щоб у навчальній та тестовій вибірках було однакове співвідношення класів

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=0, stratify=y)
```

- Розрахувати, скільки потрібно обрати найближчих записів, щоб точність була не нижче 85%

```

best_k = 0
best_cv_mean = 0
best_test_acc = 0

for k in range(1, 30):
    knn = KNeighborsClassifier(n_neighbors=k)
    cv_scores = cross_val_score(knn, X_train, y_train, cv=3)
    cv_mean = cv_scores.mean()

    knn.fit(X_train, y_train)
    test_acc = accuracy_score(y_test, knn.predict(X_test))

    if test_acc >= 0.85 and cv_mean > best_cv_mean:
        best_k = k
        best_cv_mean = cv_mean
        best_test_acc = test_acc

```

- Порахувати точність для тестової вибірки

```

- print(f"Обране k = {best_k}")
- print(f"Точність на тестовій вибірці: {best_test_acc*100:.2f}%")

```

- Зробити крос-валідацію на 3 блоках

```
- knn = KNeighborsClassifier(n_neighbors=k)
- cv_scores = cross_val_score(knn, X_train, y_train, cv=3)
```

Вивід

```
PS D:\Sofiya\vscode> & S:\moe\python.exe s:/навчання/мтад/lab4/lab4.py
Обране k = 5
Точність на тестовій вибірці: 99.36%
Середня точність крос-валідації: 99.17%
Висновок: модель досягла потрібної точності  $\geq 85\%$  та стабільна за CV
```