

Завдання 6

Кувавiна Софiя

Для вихiдних даних(тi що були в 1 завданнi) зробити:

- коробчасту дiаграму, скрипковий графiк, гiстограму, графiк густини, контурний графiк. Для будь- яких атрибутiв.
- побудувати коефiцiєнти кореляцiй для 2 атрибутiв. побудувати кореляцiйну матрицю.
- за допомогою методу **ГОЛОВНИХ КОМПОНЕНТ** визначити основнi компоненти та залежнi вiд них. спробувати iнтерпретувати новi атрибути
- розрахувати моду та стандартну похибку.
- оцiнити на який розподiл схожий розподiл ваших даних, виходячи з вигляду основних роздiлiв з теорiї ймовiрностi.
(Бiномiнiальний, Пуасоновський, Геометричний, Рiвномiрний, Показниковий або Гаусовський розподiли).
- зробити бутстрап вибiрку для 1000 значень та обрахувати довiрчий iнтервал.

1. Завантаження даних

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy import stats
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler

df = pd.read_csv(r"S:\навчання\мтад\lab1\anime_clean.csv")
for c in ['rating', 'members', 'episodes']:
    df[c] = pd.to_numeric(df[c], errors='coerce')
df = df.dropna(subset=['rating', 'members', 'episodes'])
print("Розмiрнiсть даних:", df.shape)
df.head()
```

✓ 20.1s

Розмiрнiсть даних: (11650, 7)

	anime_id	name	genre	type	episodes	rating	members
0	820	Ginga Eiyuu Densetsu	Drama, Military, Sci-Fi, Space	OVA	110.0	9.11	80679
1	15335	Gintama Movie: Kanketsu-hen - Yorozuya yo Eien...	Action, Comedy, Historical, Parody, Samurai, S...	Movie	1.0	9.10	72534
2	15417	Gintama': Enchousen	Action, Comedy, Historical, Parody, Samurai, S...	TV	13.0	9.11	81109
3	4181	Clannad: After Story	Drama, Fantasy, Romance, Slice of Life, Supern...	TV	24.0	9.06	456749
4	28851	Koe no Katachi	Drama, School, Shounen	Movie	1.0	9.05	102733

2. коробчаста дiаграма, скрипковий графiк, гiстограма, графiк густини, контурний графiк

```

scaler = StandardScaler()
X_scaled = scaler.fit_transform(df[['rating','members','episodes']])

plt.figure(figsize=(6,4))
plt.violinplot(X_scaled, showmeans=True, showextrema=True)
plt.xticks([1,2,3], ['rating','members','episodes'])
plt.title('Скрипковий графік')
plt.show()





plt.figure(figsize=(6,4))
plt.boxplot([df['rating'], df['members'], df['episodes']], tick_labels=['rating','members','episodes'], showmeans=True)
plt.title('Boxplot для атрибутів')
plt.show()


plt.hist(df['rating'], bins=30, edgecolor='black')
plt.title('Гістограма рейтингу')
plt.xlabel('rating')
plt.ylabel('кількість')
plt.show()

sns.kdeplot(df['rating'], fill=True)
plt.title('Графік густини рейтингу')
plt.show()

plt.figure(figsize=(6,4))
sns.kdeplot(x=df['members'], y=df['rating'], fill=True, cmap="mako")
plt.title('Контурний графік members vs rating')
plt.show()

```





3. побудувати коефіцієнти кореляцій для 2 атрибутів. побудувати кореляційну матрицю.


```
corr_matrix = df[['rating', 'members', 'episodes']].corr()
print('Кореляція:')
print(corr_matrix)

plt.figure(figsize=(5,4))
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm', fmt='.2f')
plt.title('Кореляційна матриця')
plt.show()
```

✓ 0.4s

Кореляція:

	rating	members	episodes
rating	1.000000	0.406805	0.083759
members	0.406805	1.000000	0.052255
episodes	0.083759	0.052255	1.000000



4. за допомогою методу **ГОЛОВНИХ КОМПОНЕНТ** визначити основні компоненти та залежні від них. спробувати інтерпретувати нові атрибути

```
scaler = StandardScaler()
X_std = scaler.fit_transform(df[['rating', 'members', 'episodes']])
pca = PCA(n_components=3)
X_pca = pca.fit_transform(X_std)

print('Внесок головних компонент:', pca.explained_variance_ratio_)
print('\nНавантаження компонентів:')
print(pd.DataFrame(pca.components_.T, columns=['PC1', 'PC2', 'PC3'], index=['rating', 'members', 'episodes']))


plt.scatter(X_pca[:,0], X_pca[:,1], s=10, alpha=0.5)
plt.title('PCA: перші дві головні компоненти')
plt.xlabel('PC1')
plt.ylabel('PC2')
plt.show()
```

✓ 0.2s

Внесок головних компонент: [0.47614204 0.32654342 0.19731454]

Навантаження компонентів:

	PC1	PC2	PC3
rating	0.694014	-0.115366	0.710658
members	0.685742	-0.194774	-0.701300
episodes	0.219324	0.974040	-0.056065



5. - розрахувати моду та стандартну похибку.

```
mode_rating = stats.mode(df['rating'], keepdims=True)[0][0]
se_rating = np.std(df['rating'], ddof=1) / np.sqrt(len(df['rating']))
print(f'Мода (rating): {mode_rating:.3f}')
print(f'Стандартна похибка (rating): {se_rating:.5f}')
```

✓ 0.0s

Мода (rating): 6.000
Стандартна похибка (rating): 0.00873

6. - оцінити на який розподіл схожий розподіл ваших даних, виходячи з вигляду основних розділів з теорії ймовірності.

(Біноміальний, Пуасоновський, Геометричний, Рівномірний, Показниковий або Гаусовський розподіли).

```
mu, sigma = stats.norm.fit(df['rating'])
ks_norm = stats.kstest(df['rating'], 'norm', args=(mu, sigma))
print('KS-тест для нормального розподілу:', ks_norm)
```

```
plt.hist(df['rating'], bins=30, density=True, alpha=0.6, color='g')
xmin, xmax = plt.xlim()
x = np.linspace(xmin, xmax, 100)
p = stats.norm.pdf(x, mu, sigma)
plt.plot(x, p, 'k', linewidth=2)
plt.title('Перевірка на нормальний розподіл')
plt.show()
```

✓ 0.1s


KS-тест для нормального розподілу: KstestResult(statistic=np.float64(0.03253714911176708),

KS-тест для нормального розподілу:

KstestResult(statistic=np.float64(0.03253714911176708),

pvalue=np.float64(3.7720910845865196e-11), statistic_location=np.float64(6.33),

statistic_sign=np.int8(-1))



За графіком видно, що форма дзвоноподібна -нагадує Гаусовський (нормальний) розподіл

Але за р-значенням (< 0.05) він не зовсім ідеально нормальний, тобто є невеликі відхилення

7. - зробити бутстрап вибірку для 1000 значень та обрахувати довірчий інтервал.

```
B = 1000
rng = np.random.default_rng(0)
boot_means = [rng.choice(df['rating'], size=len(df['rating']), replace=True).mean() for _ in range(B)]
ci_low, ci_high = np.percentile(boot_means, [2.5, 97.5])
print(f'Довірчий інтервал 95% для середнього rating: [{ci_low:.4f}; {ci_high:.4f}'])
```

✓ 0.1s

Довірчий інтервал 95% для середнього rating: [6.5171; 6.5492]