

Завдання 7

Кувавiна Софiя

Завдання:

Розробіть етапи АБ-тестування для вашого прикладу.
Задайте необхідні параметри і метрики прописані в етапах.
Згенеруйте 2 вибірки (рандомна та з наперед заданими параметрами).
Порівняйте на виході метрики та виконання критерію успіху.

Крок 1. Сформулювати гіпотези

Якщо у варіанті В штучно збільшити ймовірність конверсії ($\text{rating} \geq 7$) на 2%, то конверсія у групі В повинна стати вищою, ніж у групі А, тому що підвищення ймовірності успіху напряду має підняти середнє значення конверсії

$H_0: p_A = p_B$

$H_1: p_A \neq p_B$

Крок 2. Визначити метрики

Основна метрика це конверсія - частка записів, де $\text{rating} \geq 7$, бо вона показує, наскільки група успішна. У мене рейтинг це оцінка аніме, і я умовно вважаю, що «добре» це 7 і більше.

Додаткові метрики для аналізу це різниця $CR-B - CR-A$, z-статистика, p-value

Крок 3. Визначити критерії успіху

Критерій успіху у мене такий:

$p\text{-value} < 0.05$ - різниця між А і В статистично значуща

$CR-B - CR-A \geq MDE$, де $MDE = 1.5\%$

Це означає, що я очікую, що новий варіант має підняти конверсію хочаб на 1.5%

Крок 4. Підготувати експеримент

Групи експерименту

Група А - реальні дані, рандомна вибірка з емпіричного розподілу ($\text{rating} \geq 7 - 1$)

Група В - вибірка із штучно підвищеною ймовірністю успіху

Параметри експерименту

Розмір вибірок: 5000 для А і 5000 для В

Рівень значущості = 0.05

Мінімальний ефект - 1.5%

Крок 5. Запустити експеримент

```
import pandas as pd
import numpy as np
```

```

df = pd.read_csv(r"S:\навчання\мтад\lab1\anime_clean.csv")

if "rating" in df.columns:
    x = pd.to_numeric(df["rating"], errors="coerce")
    conv = (x >= 7).astype(float).dropna().values
else:
    num_cols = df.select_dtypes(include=[np.number]).columns
    x = pd.to_numeric(df[num_cols[0]], errors="coerce")
    thr = np.nanmedian(x)
    conv = (x >= thr).astype(float).dropna().values

rng = np.random.default_rng(17)
alpha = 0.05
MDE = 0.015
uplift = 0.02
N = min(5000, len(conv))

A = rng.choice(conv, size=N, replace=True)
pA = A.mean()

pB_target = min(pA + uplift, 0.95)
B = (rng.random(N) < pB_target).astype(float)
pB = B.mean()

def norm_cdf(x):
    import math
    t = 1.0/(1.0+0.2316419*abs(x))
    d = 0.3989423*math.exp(-x*x/2)
    prob = 1.0 - d*(1.330274*t - 1.821256*t**2 + 1.781478*t**3 - 0.356538*t**4 + 0.3193815*t**5)
    return prob if x >= 0 else 1 - prob

p_pool = (A.sum() + B.sum()) / (2 * N)
se_pool = np.sqrt(p_pool * (1 - p_pool) * (2 / N))

z = (pB - pA) / se_pool
p_value = 2 * (1 - norm_cdf(abs(z)))

print("\nРЕЗУЛЬТАТИ А/В-ТЕСТУ")
print(f"CR_A = {pA:.3%}")
print(f"CR_B = {pB:.3%}")
print(f"Різниця (B - A) = {(pB - pA):.3%}")
print(f"z-статистика = {z:.4f}")
print(f"p-value = {p_value:.6f}")

print("\nВИСНОВОК")
if p_value < alpha and (pB - pA) >= MDE:
    print("Успіх: ефект статистично значущий і досягає MDE")
else:
    print("Не успіх: ефект не проходить критерій значущості або MDE")

```

Крок 6. Проаналізувати результати

Я провела z-тест для двох пропорцій. Це стандартний тест для A/B-експериментів, де вимірюється конверсія

Результати тесту:

Різниця CR ($B - A$) = 2.820%

z-статистика = 2.9858

p-value = 0.004601

- p-value < 0.05 - результат статистично значущий
- 2.82% > MDE (1.5%) - ефект достатньо великий

РЕЗУЛЬТАТИ А/В-ТЕСТУ

CR_A = 32.160%

CR_B = 34.980%

Різниця (B - A) = 2.820%

z-статистика = 2.9858

p-value = 0.004601

ВИСНОВОК

Успіх: ефект статистично значущий і досягає MDE

Крок 7. зробити висновки

Після проведення AB-тестування я порівняла результати контрольної вибірки А та експериментальної В. У групі А конверсія склала 32.16%, а у В 34.98%, тобто варіант В показав приріст 2.82%. Це вже свідчить про покращення, але важливо було перевірити, наскільки ця різниця насправді значуща.

За допомогою z-тесту я отримала p-value 0.0046, що менше за 0.05. Це означає, що різниця між групами не випадкова, а статистично підтверджена. Крім того отриманий ефект перевищив заданий мінімальний MDE (1.5%), тобто зміна не тільки статистично значуща, але й достатньо велика, щоб вважатися корисною і у підсумку можу сказати, що експеримент вдався: гіпотеза підтвердилася, і варіант В справді працює краще