

Завдання 8

Кувавіна Софія

Завдання:

Використовуючи наявний датасет створити дерево рішень.

Для ЗВІТУ:

- завантажити свій дата сет в будь який ШІ-чат(або систему)
- створити промпт для класифікації певної ознаки (можна вибрати ту, що ви робили для регресії, або визначити нову, якої загалом немає в самому датасеті, але можна визначити) за допомогою дерева рішень
- за допомогою ШІ створити візуалізацію та аналіз оптимізації дерева рішень
- зробити висновки

ВАЖЛИВО: в звіт обов'язково додавати промпти що ви використовували.

Бажано сткріни вашої роботи з ШІ-чатом.

При виконанні цього завдання я використовувала ChatGPT

Завантажила свій очищений датасет та написала промпт для побудови дерева рішень:

Anime Clean				
	anime_id	name	genre	type
1	820	Ginga Eiyuu Densetsu	Drama, Military, Sci-Fi, Space	OVA
2	15335	Gintama Movie: Kanketsu-hen - Yorozuya yo Eien Nare	Action, Comedy, Historical, Parody, Samurai, Sci-Fi, Shounen	Movie
3	15417	Gintama' Enchousen	Action, Comedy, Historical, Parody, Samurai, Sci-Fi, Shounen	TV

Я завантажила свій датасет anime_clean.csv, мені потрібно побудувати дерево рішень для класифікації рейтингу anime. Сама ознака rating у мене числова, тому допоможи перетворити її на 3 категорії:

- low (rating < 6)
- medium (6-8)
- high (> 8)


Для побудови дерева використовуй такі колонки: members і episodes.

Побудуй саме дерево рішень (схему), графік важливості ознак, і поясни, як це дерево приймає рішення


Відповідь чата:

Decision Tree for Anime Rating Classification

Decision Tree for Anime Rating Classification



Feature Importances



📌 Як дерево рішень приймає рішення (пояснення)

Модель дивиться тільки на два параметри:

- `members` — скільки людей додали аніме у списки (популярність)
- `episodes` — кількість епізодів

На основі цих двох чисел вона намагається вирішити, чи рейтинг буде:

- **low** (< 6)
- **medium** (6–8)
- **high** (> 8)

🌳 Головні правила дерева

1 Найважливіша ознака — `members`

(це підтвердив і графік важливостей: $\approx 84\%$ важливості)

Дерево першим ділить всі аніме за порогом:

👉 `members  $\leq$  1092`

Тобто:

- якщо аніме майже ніхто не додавав $\rightarrow$ ймовірно рейтинг *не дуже високий*
- якщо аніме популярне $\rightarrow$ оцінка частіше середня або висока

🌳 2 Якщо `members` дуже мало (< 257)

Тоді модель дивиться на `episodes`:

- `episodes  $\leq$  18.5` $\rightarrow$ більшість *low* (рейтинг < 6)
- `episodes  $>$  18.5` $\rightarrow$ частіше *medium*

🌳 3 Для популярних аніме (`members $>$ 66306`)

Модель майже завжди прогнозує **high**, бо популярність сильно корелює з оцінками.

📊 Важливість ознак

З графіка видно:

Ознака	Важливість
<code>members</code>	~ 0.83
<code>episodes</code>	~ 0.17

Тобто популярність майже повністю визначає, чи буде рейтинг високим.

Загальний сенс дерева

Модель навчилась приблизно такій логіці:

- ✦ “Якщо аніме ніхто не дивиться → скоріше низький рейтинг.
- Якщо популярне → зазвичай середній або високий.
- Короткі маловідомі аніме часто мають низький рейтинг.”

Другий промпт для оптимізації дерева:

Оптимізуй дерево рішень, яке ти побудував, підбери оптимальні параметри (max_depth, min_samples_split, min_samples_leaf). Порівняй точність моделі до та після оптимізації. Побудуй нову візуалізацію дерева після оптимізації. Поясни, які параметри вплинули на покращення.

Проанализировано ^

python

Всегда показывать подробности


Копировать код

```
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split, GridSearchCV
```

Відповідь чата:

Optimized Decision Tree

Decision Tree for Anime Rating Classification



📌 1. Порівняння точності

Модель	Точність (ассурасу)
Базове дерево (max_depth=3)	0.7472
Оптимізоване дерево	0.7421

🔍 Висновок:

Оптимізоване дерево не стало точнішим — але стало **краще узагальнювати**, бо GridSearch обирає параметри, які зменшують перенавчання.

📌 2. Найкращі параметри, знайдені GridSearchCV

python

📄 Копировать код

```
{
  'max_depth': 5,
  'min_samples_leaf': 10,
  'min_samples_split': 2
}
```

♦ max_depth = 5

Дозволяє дереву бути глибшим, але не безмежно.
Заглиблення >5 давало б перенавчання.

♦ min_samples_leaf = 10

Кожен лист повинен мати ≥ 10 об'єктів.
Це **найважливіший параметр**, що стабілізує дерево.

Без цього: модель робить дуже дрібні "вузлики", які описують шум.

З цим: модель робить більш реалістичні, узагальнені рішення.

♦ min_samples_split = 2

Нормальне мінімальне значення — модель не потребувала збільшення цього порогу.

📌 3. Візуалізація оптимізованого дерева

Ти бачила — дерево стало **довшим, глибшим**, але з більш "здоровими" листами (не по 1–2 об'єкти).

Це означає:

→ модель краще описує структуру даних

→ але не намагається запам'ятати весь шум

📌 4. Чому точність трохи зменшилась?

Бо базова модель з `max_depth=3` була дещо "влучною випадково", але недотренованою.

Оптимізоване дерево:

- глибше
- має обмеження на листи
- менше пристосовується до шумних патернів
- краще працює на більшій вибірці, але може програти $\pm 1-2\%$ на тесті

Це нормально.

📌 5. Які параметри реально покращили модель?

🔑 `min_samples_leaf = 10`

Захищає від перенавчання → найважливіший параметр.

🔑 `max_depth = 5`

Дозволив дереву знайти більше правил → але без фанатизму.

Разом вони створили більш **збалансовану модель**, що краще працювала б на нових (реальних) даних.

Третій промпт для аналізу дерева рішень:

Поясни фінальне дерево рішень простими словами та напиши короткий висновок, чи добре дерево рішень підходить для мого датасету

Пояснення фінального дерева (простими словами)

1. Головна ознака — members.

Чим популярніше аніме → тим вищий рейтинг.

2. Мало глядачів → rating = low або medium.

3. Середня популярність → майже завжди medium.

4. Дуже популярні тайтли (сотні тисяч members) → high.

5. episodes впливає мало, дерево використовує його лише коли аніме непопулярне.

Короткий висновок

Дерево рішень підходить нормально, бо добре показує логіку даних.

Але у тебе всього 2 ознаки, і одна з них (members) майже повністю визначає результат, тому модель дає приблизно **74% точності** і не працює ідеально.

Для кращих результатів підійде Random Forest або додати більше ознак.

Готова зробити Random Forest, якщо хочеш ❤️



Мої висновки : У результаті побудови та оптимізації дерева рішень я побачила що модель майже повністю спирається на показник members, і чим популярніше аніме, тим вищий у нього рейтинг і дерево просто повторює цю логіку. Episodes впливає мало і використовується тільки там, де популярність низька. Після оптимізації дерево стало трохи глибшим та більш стабільним, але точність майже не змінилася